

DOCUMENTACIÓN TÉCNICA

Sistema de Alerta Temprana de Fraude Biométrico

BiometríaA

Proyecto Final — Machine Learning (Deep Learning)

 Autor(es)	Harley Alejandro Pulido Cardona
 Fecha	28/06/2026
 Versión	v1.0
 Demo URL	Ver Aplicación en Streamlit
 Repositorio	Ver Repositorio en GitHub

1. Información General del Sistema

Nombre del modelo	Sistema de Alerta Temprana de Fraude Biométrico
Tipo de modelo	Clasificación binaria supervisada (Deep Learning)
Dataset utilizado	Dataset sintético parametrizado basado en reglas de negocio de sucursales bancarias (100,000 filas)
Variable objetivo	es_fraude (1: Ataque/Fraude, 0: Cliente Genuino)

2. Resumen Ejecutivo

El sistema evalúa en tiempo real el comportamiento de autenticación biométrica de clientes en sucursales bancarias para predecir la probabilidad de un ataque de suplantación (ej. uso de huellas sintéticas).

Analizando ventanas de tiempo, intentos fallidos y sucursales visitadas, el modelo protege a las entidades financieras reduciendo el riesgo de materialización de fraudes, sin penalizar injustamente a clientes legítimos con dificultades de autenticación (como dermatitis).

3. Problema y Contexto

3.1 Problema Identificado

En sucursales físicas bancarias, se usa un método de autenticación de biometría dactilar. Las entidades bancarias requieren validar la identidad por método de biometría dactilar del cliente para realizar cualquier operación (retiros, actualizar datos, etc.). La forma de suplantación de identidad que usan los criminales es el uso de huellas sintéticas. Aunque el captor biométrico tiene remediación de fraude, se tiene el riesgo de que, después de varios intentos en diferentes sucursales, el fraude pueda materializarse.

Particularidad: Pueden existir clientes con dermatitis o huellas desgastadas, lo que puede significar más intentos para lograr una biometría exitosa, dificultando la diferenciación entre un ataque y un cliente con problemas legítimos.

3.2 Justificación del Uso de IA

Se requiere el uso de IA para identificar anomalías en los intentos de autenticación por biometría dactilar de las últimas horas, ya que el problema depende de múltiples variables no lineales que un modelo puede aprender mejor que reglas manuales estrictas.

Lógica de análisis de anomalías que la IA debe interpretar:

- **Ventana de horas:** Ventana de horas más larga disminuye el riesgo.
- **Cantidad total de intentos:** Más intentos aumentan el riesgo.
- **Sucursales distintas visitadas:** Más sucursales visitadas aumentan el riesgo.
- **Intentos exitosos:** Más intentos exitosos disminuyen el riesgo.

4. Arquitectura del Modelo

El flujo del sistema se compone de cuatro fases:

1. **Entrada:** Captura de datos transaccionales del usuario desde la interfaz.
2. **Procesamiento (Feature Engineering):** Cálculo automático de la *tasa_errores* y escalado matemático de los datos (StandardScaler) para compatibilidad neuronal.
3. **Modelo:** Inferencia a través de una Red Neuronal (Perceptrón Multicapa) previamente entrenada.
4. **Salida:** Devolución de un porcentaje de probabilidad y clasificación en 3 niveles de riesgo.

5. Datos y Variables

- **Fuente del dataset:** Datos sintéticos generados en Python mediante parametrización estadística de reglas de negocio.
- **Número de registros:** 100,000 filas.
- **Variables utilizadas:** rango_horas, cantidad_intentos_transaccion, cantidad_transacciones_exitosas, cantidad_sucursales_distintas, tasa_errores (calculada).
- **Variables descartadas:** ID del cliente o nombres (para evitar sobreajuste y proteger PII).
- **Tipo de datos:** Numéricos continuos y discretos.

6. Modelo de IA Utilizado

- **Algoritmo:** Red Neuronal Profunda / Perceptrón Multicapa (MLP). (Nota: Se realizó un exhaustivo benchmark previo evaluando Isolation Forest, LightGBM, XGBoost y Random Forest. Aunque Isolation Forest mostró buenos resultados en detección de anomalías espaciales, la Red Neuronal fue el modelo ganador por su capacidad de generalización y captura de relaciones no lineales).
- **Librerías:** TensorFlow, Keras, scikit-learn, pandas.
- **Hiperparámetros:** Arquitectura de 2 capas ocultas (6 y 16 neuronas), activación ReLU, función de salida sigmoid, optimizador Adam, y capas de Dropout (0.3 y 0.2) para prevenir el sobreajuste.
- **Tipo de aprendizaje:** Supervisado.

7. Entrenamiento y Evaluación

- **División de datos:** 80% Entrenamiento (train), 20% Prueba (test) usando división estratificada para mantener la proporción de fraudes.
- **Métricas obtenidas (Modelo ganador):** Accuracy: 0.9946 | Loss: 0.0172 | ROC-AUC: 0.9987
- **Resultados:** La red neuronal logró mapear perfectamente la lógica de negocio, discriminando con alta precisión entre ataques distribuidos de fuerza bruta y usuarios genuinos con condiciones como dermatitis.

8. Interpretabilidad

- **Variables más importantes:** tasa_errores y cantidad_sucursales_distintas.
- **Explicación del modelo:** El modelo penaliza severamente el comportamiento comprimido en el tiempo (pocas horas) combinado con altos intentos fallidos en múltiples sucursales (patrón clásico de bot o atacante sintético). Por el contrario, perdona los altos intentos si la tasa de éxito final es proporcional y se distribuye en un rango de horas lógico (patrón de cliente con desgaste dactilar).

9. Uso del Modelo

1. El analista o sistema central ingresa la volumetría de transacciones biométricas del cliente en una ventana de tiempo.
2. El sistema reordena las variables y las estandariza.
3. El modelo de Deep Learning genera una probabilidad de fraude (0% a 100%).
4. El sistema clasifica el riesgo:
 - **Riesgo Nulo:** < 50% de probabilidad.
 - **Riesgo Medio:** > 50% de probabilidad.
 - **Riesgo Alto:** > 90% de probabilidad.

10. Implementación Técnica

- **Backend & Frontend:** Streamlit (Python).
- **Modelo:** Archivo nativo .keras para la red neuronal, acompañado de dos artefactos joblib (scaler_dl.joblib para estandarización y columnas_dl.joblib para integridad del tensor de entrada).
- **Despliegue:** <https://biometricfraudmodel-rtysgubvsqsb5rcmvnd5z8.streamlit.app/>

11. Resultados y Valor

El modelo permite a la entidad bancaria pasar de un análisis reactivo a uno predictivo. Reduce drásticamente los falsos positivos en clientes con afecciones dermatológicas y bloquea preventivamente a los estafadores que utilizan huellas sintéticas antes de que el fraude económico se materialice, ahorrando millones en pérdidas.

12. Limitaciones

El modelo actual se basa en un dataset sintético. Aunque fue parametrizado estrictamente bajo reglas de negocio reales, el comportamiento humano real posee un nivel de "ruido" estadístico que los datos sintéticos no siempre capturan. El modelo requerirá un reentrenamiento (Fine-tuning) una vez que se recolecte data en vivo de los captores biométricos de las sucursales.

13. Ética y Seguridad

El modelo fue diseñado priorizando la equidad algorítmica para asegurar que las personas con problemas físicos (dermatitis, edad avanzada) no sean bloqueadas sistemáticamente del sistema bancario. Además, el modelo ingiere datos puramente de comportamiento volumétrico, sin requerir procesamiento de Identificación Personal (PII), garantizando el cumplimiento de leyes de protección de datos.

14. Manual de Uso

- **Paso 1:** En la pantalla principal, introducir en los campos numéricos la información de la sesión biométrica (Horas transcurridas, Intentos totales, Éxitos y Sucursales visitadas).
- **Paso 2:** Presionar el botón principal "Evaluar con Inteligencia Artificial".
- **Paso 3:** Interpretar la barra de progreso. Si el semáforo arroja Riesgo Medio, se solicitará al cliente en la sucursal un OTP (Token celular). Si arroja Riesgo Alto, se realizará un bloqueo preventivo de la cuenta.